ML,DL

[ML/DL] 회귀(Regression)의 정의와 구현

2021. 1. 7. 18:43 수정 삭제 공개

회귀(Regression)

1-1.회귀(Regression)란?

회귀는 독립변수와 한개의 종속 변수간의 상관관계를 모델링 하는 기법으로 보통 머신러닝의 회귀 예측의 핵심은 주어진 피처(속성/독립변수)와 결정 값(종속변수) 데이터 기반에서 학습을 통해 최적의 회귀계수를 찾아내는 것!
간단하게 A(독립변수)와 B(종속변수) 둘의 인과관계나 둘의 연관성? 등을 통해 A라는 속성만 있을 때 B의 값을 예측하는 것이다.

1-2.회귀의 종류

회귀의 종류는 독립변수의 개수에 따라 달라진다.

- 단순선형회귀 - 독립변수 1개
- 다중선형회귀 - 독립변수 2개이상

분류와 회귀의 가장 큰 차이는 값의 차이다. 분류는 카테고리값(이산값)이고 회귀의 결과값은 숫자값(연속값)으로 되어있다.

1-3.구현

```
# 그래프를 그리는데 필요한 라이브러리
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline


# 한글 폰트 문제 해결
import platform

from matplotlib import font_manager, rc
# plt.rcParams['axes.unicode_minus'] = False

if platform.system() == 'Darwin':
    rc('font', family='AppleGothic')
elif platform.system() == 'Windows':
    path = "c:/Windows/Fonts/malgun.ttf"
    font_name = font_manager.FontProperties(fname=path).get_name()
    rc('font', family=font_name)
else:
    print('Unknown system... sorry~~~~')



import matplotlib
matplotlib.rcParams['axes.unicode_minus']=False


# 키(meter)와 몸무게 (kg)
heights = [[1.6],[1.65],[1.7],[1.77],[1.85]]
weights = [[60],[65],[70],[77],[80]]


plt.title('키&몸무게 그래프')
plt.xlabel('키')
plt.ylabel('몸무게')
plt.plot(heights, weights)
plt.axis([1.5,1.90,55,90]) #  범위
plt.show()
```

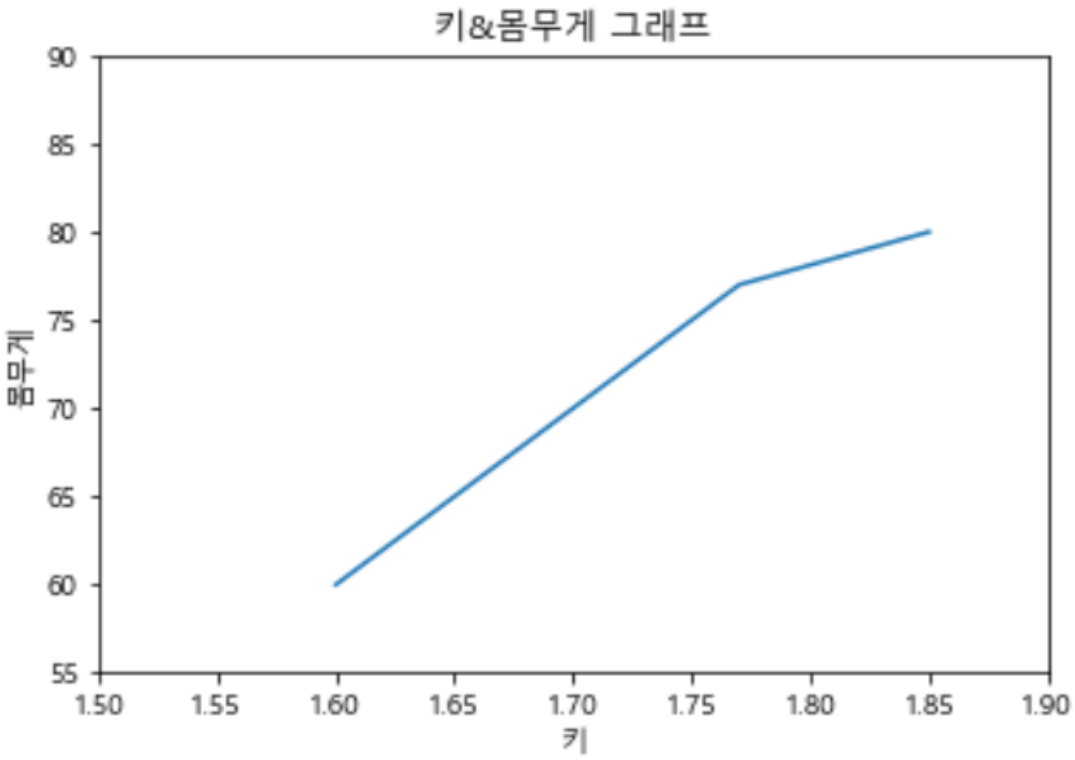


```
# 회귀나 머신러닝을 할때 sklearn을 사용한다. 여기서는 LinearRegression을 쓴다.

# 라이브러리를 가져오고
from sklearn.linear_model import LinearRegression

# LinearRegression을 쓰기위해 LinearRegression 함수를 lr_model에 저장한다.
lr_model = LinearRegression()


# fit 함수를 통해 내가 가진 데이터를 모델에 학습한다.
lr_model.fit(heights,weights)


#값을 예측해 본다. predict을 통해 예측을 한다. 여기서는 키가 1.7일때와 1.75일때의 몸무게를 예측
weight_pred = lr_model.predict([[1.7,],[1.75]])
weight_pred
```

예측 결과 값이 이렇게 두개가 나온다.

```
array([[69.24460432],
       [73.37101747]])
```

```
# 그래프를 그리는데 여러가지 값을 넣어주고
plt.title('키 & 몸무게 그래프')
plt.xlabel('키')
plt.ylabel('몸무게')
plt.grid(True)
plt.grid(True)
plt.axis([1.5,1.90,55,90])


#선형 회귀 선을 그린다.
plt.plot(heights,weights,'k.')

#여기서는 heights에 대해 예측한 값을 y에 넣고 그래프를 그린다.
plt.plot(heights, lr_model.predict(heights),color='blue')

# 그래프를 그린다.
plt.show()
```

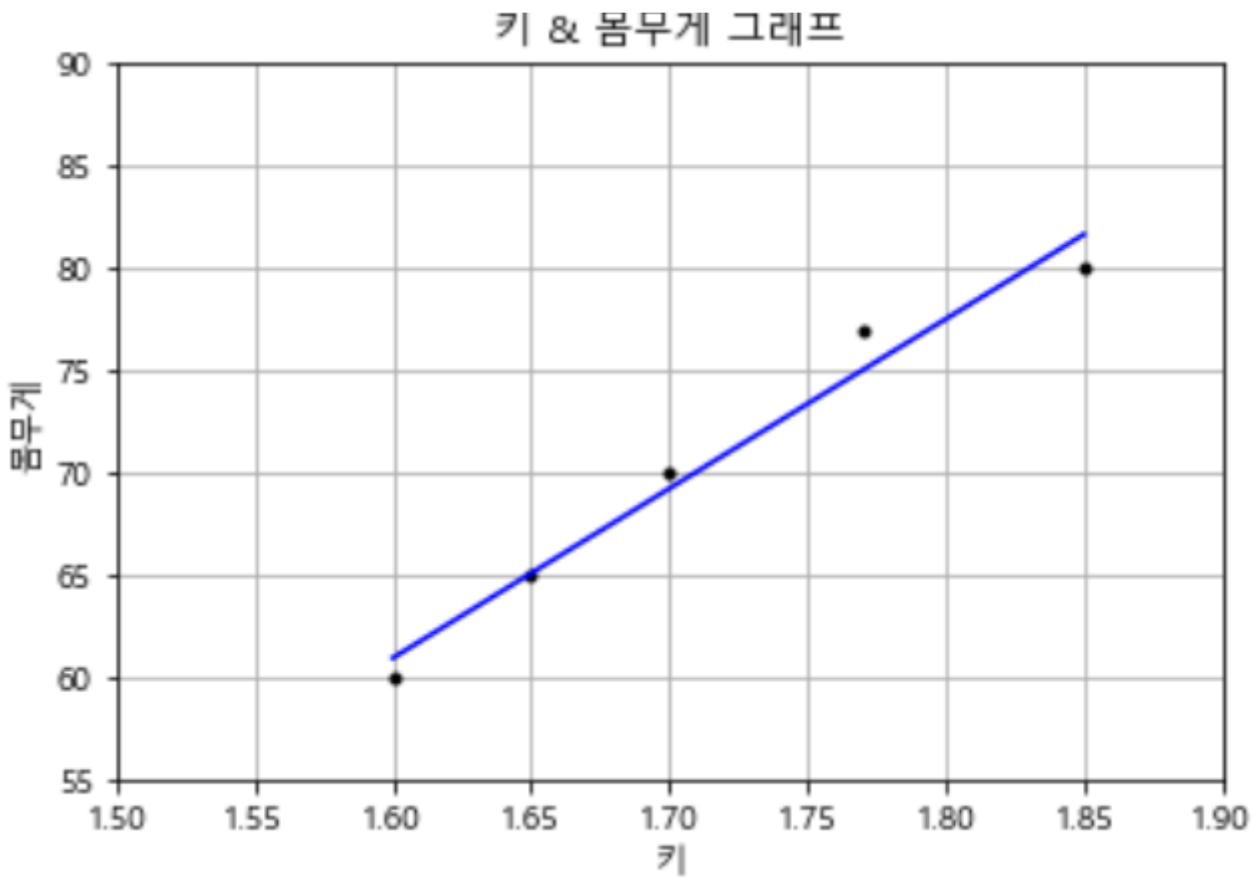

이렇게 예측에 따른 그래프를 그린다.

예제

```
## auto-mpg.csv 을 이용한 선형회귀

import pandas as pd

import numpy as np

row_data = pd.read_csv('../data/auto-mpg.csv')

row_data.columns = ['mpg','cylinders','displacement','horsepower','weight','acceleration','model y

row_data.head()
```

	mpg	cylinders	displacement	horsepower	weight	acceleration
0	15.0	8	350.0	165.0	3693.0	11.5
1	18.0	8	318.0	150.0	3436.0	11.0
2	16.0	8	304.0	150.0	3433.0	12.0
3	17.0	8	302.0	140.0	3449.0	10.5
4	15.0	8	429.0	198.0	4341.0	10.0

```
# 데이터의 자료형 확인

row_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 397 entries, 0 to 396
Data columns (total 9 columns):
mpg             397 non-null float64
cylinders       397 non-null int64
displacement    397 non-null float64
horsepower      397 non-null object
weight          397 non-null float64
acceleration    397 non-null float64
model year      397 non-null int64
origin          397 non-null int64
name            397 non-null object
dtypes: float64(4), int64(3), object(2)
memory usage: 28.0+ KB
```

- horsepower 전처리

```
row_data['horsepower'].replace('?',np.nan,inplace=True)

row_data['horsepower'].unique()



row_data.dropna(subset=['horsepower'],axis=0,inplace=True)

row_data['horsepower'] = row_data['horsepower'].astype('float')

row_data['horsepower'].unique()


row_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 391 entries, 0 to 396
Data columns (total 9 columns):
mpg             391 non-null float64
cylinders       391 non-null int64
displacement    391 non-null float64
horsepower      391 non-null float64
weight          391 non-null float64
acceleration    391 non-null float64
model year      391 non-null int64
origin          391 non-null int64
name            391 non-null object
dtypes: float64(5), int64(3), object(1)
memory usage: 30.5+ KB
```

```
# 분석에 활용할 독립변수 선택

cor_df = row_data[['mpg','cylinders','horsepower','weight']]

cor_df.head()
```

	mpg	cylinders	horsepower	weight
0	15.0	8	165.0	3693.0
1	18.0	8	150.0	3436.0
2	16.0	8	150.0	3433.0
3	17.0	8	140.0	3449.0
4	15.0	8	198.0	4341.0

```
# seaborn 산점도

fig = plt.figure(figsize=10,5)

area01 = fig.add_subplot(1,2,1)

area02 = fig.add_subplot(1,2,2)

sns.regplot(x='weight',y='mpg',data=cor_df,ax=area01)

sns.regplot(x='weight',y='mpg',data=cor_df,ax=area02,fit_reg=False)


plt.show()
```

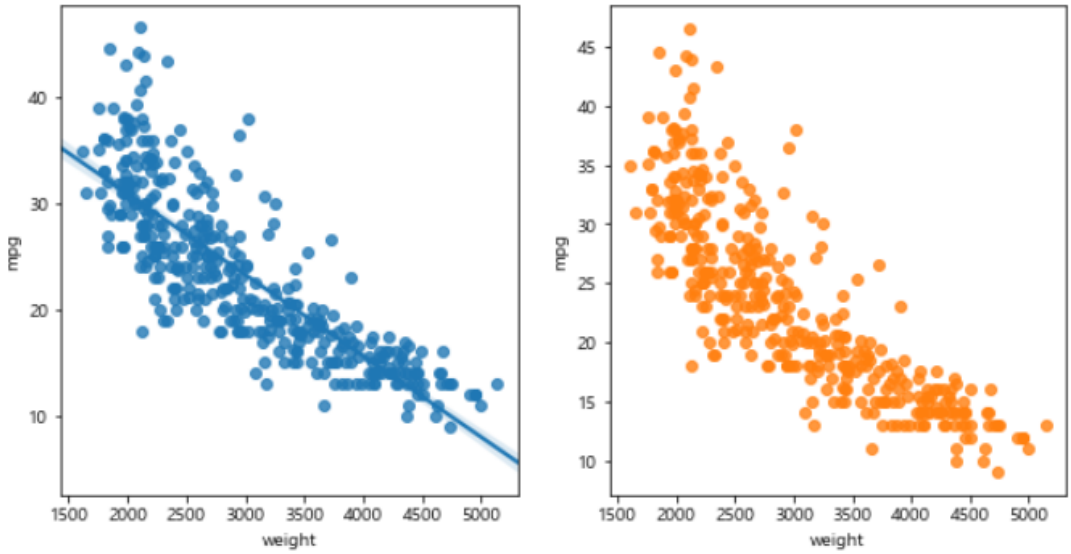


```
sns.pairplot(cor_df)

plt.show()
```

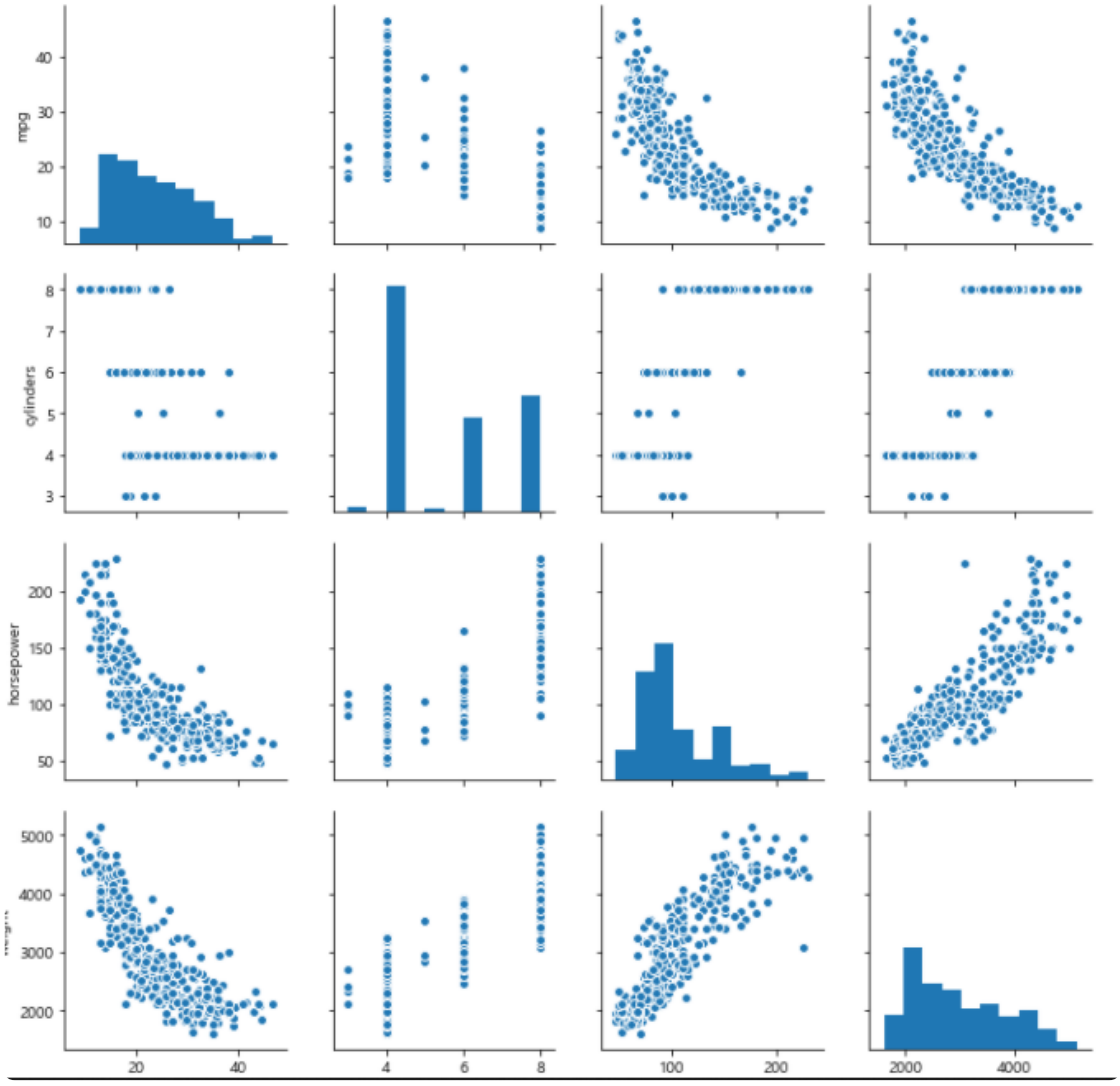


```
# 독립변수

X = cor_df[['weight','horsepower']]


#종속변수

y = cor_df['mpg']



#데이터세트를 구분

from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2,random_state=10)

print(len(X_train))

print(len(X_test))
```

```
312
79
```

```
from sklearn.linear_model import LinearRegression
auto_lr_model = LinearRegression()


auto_lr_model.fit(X_train,y_train)
```

```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize
=False)
```

```
auto_lr_model.fit(X_train,y_train)

r_square = auto_lr_model.score(X_test,y_test)

print('결정계수 :',r_square)
```

```
결정계수 : 0.7424945106468799
```

```
# 회귀의 기울기

print('기울기:', auto_lr_model.coef_)


# 회귀의 절편

print('절편:', auto_lr_model.intercept_)
```

```
기울기: [-0.00583815 -0.04693779]
절편: 45.804275870409555
```

```
# 모델에 전체 X 데이터를 입력하여 예측값, 실제값
y_pred = auto_lr_model.predict(X)
y_pred = auto_lr_model.predict(X)

pred_answer = pd.DataFrame(data={'answer ': y, 'prediction' : y_pred })
pred_answer.head()
```

	answer	prediction
0	15.0	16.499242
1	18.0	18.703714
2	16.0	18.721229
3	17.0	19.097196
4	15.0	11.167172

```
sns.distplot(y,hist=False,label='answer')
sns.distplot(y_pred,hist=False,label='guess')
plt.show()
```

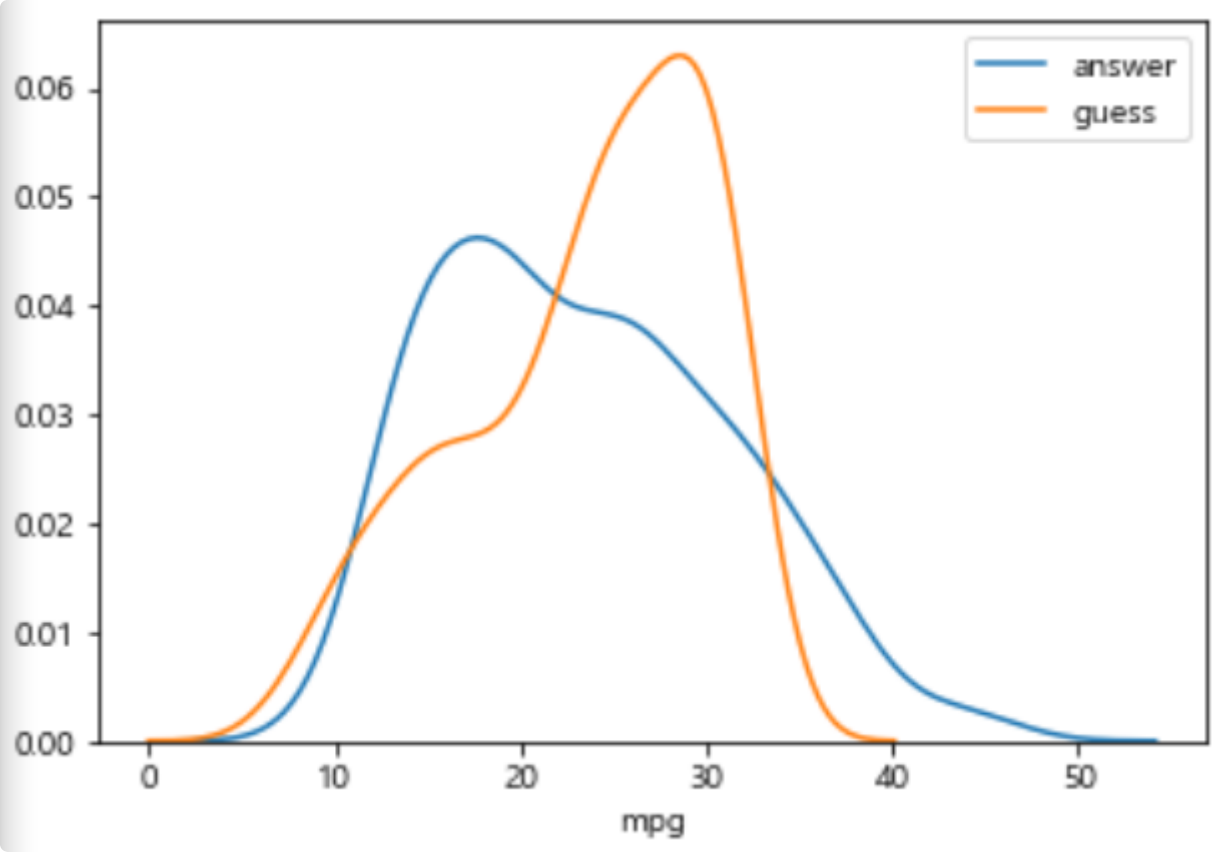

이건 예측값과 답에 대한 그래프를 그렸을 때의 결과이다.

'ML,DL' 카테고리의 다른 글□

[ML/DL] 회귀(Regression)의 정의와 구현□

[ML/DL] 군집화의 정의와 종류 및 구현□

[ML/DL] XGboost의 정의와 구현 및 hyper parameter 설정□

[ML/DL] 앙상블 학습 (Ensemble Learning): 3.Boosting(부스팅)이란?□

[ML/DL] 앙상블 학습 (Ensemble Learning): 2. Voting(보팅)이란?□

[ML/DL] 앙상블 학습 (Ensemble Learning): 1. bagging(배깅)이란?□

regression Regression 분석 회귀 회귀란 회귀분석

나아무늘보

혼자 끄적끄적하는 블로그 입니다.